

Optimisation de l'algorithme K-Means à travers une méthode automatique de détection du nombre optimal de clusters et les centroids.

Saidi Fatma Zohra
Kaci Aissa Maissa

12 Avril 2025

Abstract

Ce rapport présente une méthode automatisée pour déterminer le nombre optimal de clusters et sélectionner les centroïdes de manière plus efficace. À travers l'utilisation de la réduction de dimensionnalité via l'analyse en composantes principales (PCA) et une approche basée sur la distribution gaussienne, l'algorithme propose une approche innovante pour améliorer les résultats de K-Means.

1 Introduction

L'algorithme K-Means est un outil populaire pour le clustering, mais il présente des défis, notamment le choix du nombre optimal de clusters (K) et l'initialisation aléatoire des centroïdes. Ce rapport présente une méthode automatisée pour déterminer K, basée sur la distribution gaussienne des données, et sélectionne les centroïdes à l'aide d'une méthode systématique de partitionnement basée sur la variance.

Le nombre optimal de clusters est déterminé en analysant la distribution des données, en s'appuyant sur l'hypothèse que les données suivent une distribution gaussienne. Ensuite, les centroïdes sont choisis en partitionnant les données le long de l'axe ayant la plus grande variance. Ce processus de partitionnement améliore la répartition des centroïdes, rendant l'algorithme plus efficace et précis.

2 Méthodologie

2.1 Détermination du nombre optimal de clusters

Pour déterminer le bon nombre de clusters, on utilise l'algorithme G-Means. Cet algorithme commence avec un petit nombre de clusters (2), puis applique K-Means pour séparer les données. Ensuite, il teste si les points dans chaque cluster suivent une distribution gaussienne (normale) en utilisant le test d'Anderson-Darling. Si ce n'est pas le cas, cela veut dire que le cluster contient probablement plusieurs groupes, donc on le divise en deux et on continue. Ce processus se répète jusqu'à ce que tous les clusters aient une distribution proche de la gaussienne. À la fin, le nombre de clusters trouvé est considéré comme optimal.




Figure 1: Distribution des Données Projetées vs. Courbe Gaussienne Idéale

2.1.1 Limites de la méthode et amélioration proposée

Même si l'algorithme G-Means est efficace pour trouver automatiquement le nombre de clusters, il présente certains inconvénients. Il a tendance de diviser les clusters jusqu'à ce que la distribution soit parfaitement gaussienne, ce qui peut mener à un nombre de clusters trop élevé. Pour limiter ce problème, nous avons ajouté une contrainte supplémentaire : si le score de silhouette diminue après une division, alors on annule cette division. Cela permet de garder uniquement les séparations qui améliorent la qualité du clustering, et d'éviter une sur-segmentation inutile.

2.2 Sélection des centroïdes

Pour améliorer l'initialisation des centroïdes dans l'algorithme K-Means, cette méthode propose de partitionner les données selon l'axe ayant la plus grande variance. Cet axe permet de mieux séparer les points de manière naturelle. Les données sont triées le long de cet axe, puis on cherche un point de coupure qui minimise l'erreur totale de regroupement. Les données sont alors divisées en deux groupes, et on calcule le centroïde de chaque groupe comme la moyenne des points qu'il contient. Ce processus est répété de manière adaptative, en choisissant à chaque étape le groupe à diviser qui réduit le plus l'erreur, jusqu'à ce qu'aucune division significative ne soit possible.

2.2.1 Avantages de la méthode

- Elle permet d'éviter l'initialisation aléatoire, ce qui améliore la stabilité et la qualité des résultats.
- En choisissant des centroïdes bien répartis et éloignés les uns des autres, elle augmente la probabilité de former des clusters cohérents dès le début. Cela aide non seulement l'algorithme K-Means à converger plus rapidement (car les centroïdes sont déjà proches des zones denses), mais améliore aussi G-Means, car les clusters initiaux sont mieux formés pour les tests de normalité.
- En splittant à la distance du centroïde le long de la direction de plus grande variance, les nouveaux centroïdes sont naturellement éloignés les uns des autres, ce qui maximise la distance inter-classe et favorise une bonne séparation entre les clusters.
- En recalculant les centroïdes comme la moyenne des sous-partitions, on garantit que chaque cluster reste compact autour de son centroïde, ce qui réduit la distance intra-classe.

Ainsi, cette méthode améliore la compacité et la séparation des clusters dès l'initialisation, ce qui contribue fortement à la qualité du partitionnement final. De plus, elle réduit souvent le nombre d'itérations nécessaires pour atteindre la convergence, rendant l'algorithme plus rapide et plus efficace.

3 Analyse des Résultats Expérimentaux

3.1 Nombre d'itérations pour chaque solution

Pour évaluer l'efficacité de la méthode proposée, nous avons comparé deux solutions:

Solution 1: G-Means avec score de silhouette et initialisation aléatoire des centroïdes.

Solution 2: G-Means avec score de silhouette et initialisation des centroïdes par partitionnement.

Les deux versions ont été testées sur plusieurs Datasets(Iris, Wine, Digits, etc.), mesurant les itérations nécessaires à la convergence de K-Means, et voici les résultats:

DATASET	Iterations	
	Solution 1	Solution 2
Iris	12	4
Wine	9	6
Blobs	10	5

Table 1: Comparaison du nombre d'itérations nécessaires pour la solution 1 et solution 2.

Les résultats montrent une réduction significative du nombre d'itérations nécessaires pour la convergence avec la Solution 2 par rapport à la Solution 1.

3.2 Précision des solutions 1 et 2

La Solution 2 présente généralement une meilleure précision, notamment en raison du choix plus optimisé des centroïdes initiaux. Contrairement à la Solution 1, où les centroïdes sont choisis aléatoirement, la Solution 2 utilise une méthode de sélection qui permet d'obtenir des centroïdes plus proches des points centraux des clusters dès le départ. Cela réduit le nombre d'itérations nécessaires pour converger et améliore la précision globale de l'algorithme.

En ce qui concerne les distributions, le fait de choisir des centroïdes non aléatoires aide à mieux capturer les caractéristiques des données, surtout lorsqu'elles suivent des distributions gaussiennes. Cela signifie que les clusters sont mieux définis dès le début, ce qui permet à l'algorithme de mieux




Figure 2: Accuracy comparison.

séparer les données et d’atteindre une solution plus précise. Pour des jeux de données comme Blobs, Moons, et Circles, où les clusters sont bien séparés, un bon choix de centroïdes améliore fortement l’alignement avec la structure réelle des données, ce qui se traduit par des résultats d’accuracy plus élevés.

En résumé, la Solution 2 bénéficie d’une meilleure initialisation des centroïdes, ce qui améliore l’efficacité et la précision de l’algorithme K-Means, notamment pour des distributions bien structurées comme celles observées dans vos jeux de données.

4 Conclusion

En conclusion, les résultats expérimentaux montrent que la Solution 2, avec une initialisation optimisée des centroïdes, surpasse la Solution 1 dans plusieurs aspects. Non seulement elle réduit le nombre d’itérations nécessaires pour la convergence, mais elle offre également une meilleure précision, notamment pour les Datasets où les clusters sont bien séparés. Cette amélioration de la précision peut être expliquée par une initialisation des centroïdes qui permet une meilleure séparation des clusters dès le début, facilitant ainsi la convergence de l’algorithme et améliorant ses performances globales. Ainsi, la Solution 2 présente un intérêt majeur pour des applications nécessitant des algorithmes de clustering efficaces et précis, tout en réduisant le temps de calcul.