

Optimisation de l'algorithme K-Means à travers une méthode automatique de détection du nombre optimal de clusters et les centroids.

Saidi Fatma Zohra
Kaci Aissa Maissa

12 Avril 2025

Abstract

Ce rapport présente une méthode automatisée pour déterminer le nombre optimal de clusters et sélectionner les centroïdes de manière plus efficace. À travers l'utilisation de la réduction de dimensionnalité via l'analyse en composantes principales (PCA) et une approche basée sur la distribution gaussienne, l'algorithme propose une approche innovante pour améliorer les résultats de K-Means.

1 Introduction

L'algorithme K-Means est un outil populaire pour le clustering, mais il présente des défis, notamment le choix du nombre optimal de clusters (K) et l'initialisation aléatoire des centroïdes. Ce rapport présente une méthode automatisée pour déterminer K , basée sur la distribution gaussienne des données, et sélectionne les centroïdes à l'aide d'une méthode systématique de partitionnement basée sur la variance.

2 Méthodologie

2.1 Détermination du nombre optimal de clusters

Pour déterminer le bon nombre de clusters, on utilise l'algorithme G-Means. Voici un pseudocode de cette solution :

Algorithme G-Means [1]

1. Préparation des Données

- Réduire la dimension avec PCA (garder 2 à 10 composantes).
- Normaliser les données.

2. Initialisation

- Commencer avec 1 cluster (centre = moyenne globale des données).
- Définir $k_{\max}$ selon la taille du dataset.

3. Boucle Principale (tant que $k_{\text{actuel}} < k_{\max}$)

- Appliquer K-means avec k_{actuel} clusters.
- Calculer le score de silhouette (si $k_{\text{actuel}} > 1$), si le score baisse $\rightarrow$ arrêter.
- Pour chaque cluster :
 - Vérifier s'il contient au moins 2% des données.
 - Tester si le cluster suit une distribution gaussienne :
 - * Centrer les données autour du centroïde.
 - * Projeter sur la direction de plus grande variance (1D).
 - * Appliquer le test d'Anderson-Darling.
 - * Si non gaussien (stat > seuil critique) $\rightarrow$ splitter le cluster.
- Si aucun cluster n'est split $\rightarrow$ convergence atteinte.

4. Résultat

- Retourner le nombre final de clusters et le nombre d'itérations.

Test d'Anderson-Darling: Le test d'Anderson-Darling évalue si un échantillon de données suit une distribution normale. Sa statistique A^2 est calculée comme suit :

$$A^2 = -n - \frac{1}{n} \sum_{i=1}^n (2i-1) [\ln(F(x_i)) + \ln(1 - F(x_{n-i+1}))] \quad (1)$$

où:

- n = nombre de points de données
- x_i = valeurs des données triées par ordre croissant
- $F(x_i)$ = Fonction de répartition (CDF) de la loi normale standard

Interprétation:

- $A^2 \approx 0 \Rightarrow$ les données suivent une distribution normale

2.1.1 Limites de la méthode et amélioration proposée

- **Projection unidirectionnelle :** Le test d'Anderson-Darling ne vérifie la normalité que **sur un seul axe** (direction de plus grande variance). Ceci peut ignorer des non-normalités multidimensionnelles complexes (p.ex. clusters en forme de croissant ou anneau).
- **Exigence de normalité parfaite :** Le test suppose une distribution **parfaitement gaussienne**. En pratique, les clusters naturels présentent souvent des queues épaisses ou asymétries, conduisant à des divisions excessives.

- **Solution apportée** : Contrôle par **score de silhouette** après chaque division :
 - si le score de silhouette diminue après une division, alors on annule cette division




Figure 1: Distribution des données projetées après application de l'algorithme G-means vs courbe gaussienne idéale

2.2 Sélection des centroïdes

Pour améliorer l'initialisation des centroïdes dans l'algorithme K-Means, cette méthode propose de partitionner les données selon l'axe ayant la plus grande variance. Voici un pseudocode de cette solution :

Algorithme sélection des centroids [2]

1. Choix de l'axe principal

- Calculer la variance pour chaque axe
- Sélectionner l'axe avec variance maximale

2. Tri et calcul des distances

- Trier les points selon l'axe sélectionné
- Calculer les distances carrées entre points adjacents
- Calculer la somme cumulative ($dsum$)

3. Détermination du point optimal

- Calculer $centroidDist = moyenne(dsum)$
- Trouver le point m où $|dsum - centroidDist|$ est minimale

4. Création des nouveaux centroïdes

- Calculer moyenne des points avant $m \rightarrow c_1$
- Calculer moyenne des points après $m \rightarrow c_2$

Exemple explicatif: Appliquons l'algorithme de choix des centroids sur cette matrice de données:

Point	X (Feature 1)	Y (Feature 2)
P1	1.0	1.0
P2	1.5	2.0
P3	2.0	1.5
P4	3.0	4.0
P5	3.5	3.5
P6	4.0	5.0
P7	5.0	4.5
P8	6.0	5.0
P9	6.5	6.0
P10	7.0	7.0

Table 1: Coordonnées des points selon deux caractéristiques

1. Choix de l'axe principal:

- On calcule la variance de chaque axe: $\text{var}(X) = 4.15$, et $\text{var}(Y) = 3.83$.
- On choisit l'axe X.

2. Trier et calculer les distances:

- Les données sont déjà triées selon l'axe X.
- le calcul des distances carrées entre points adjacentes et la somme cumulative:

Distances adjacentes (D_j)

Paire	D_j
P1-P2	0.25
P2-P3	0.25
P3-P4	1.0
P4-P5	0.25
P5-P6	0.25
P6-P7	1.0
P7-P8	1.0
P8-P9	0.25
P9-P10	0.25

Distances cumulées ($dsum_i$)

Point	$dsum_i$
P1	0.0
P2	0.25
P3	0.5
P4	1.5
P5	1.75
P6	2.0
P7	3.0
P8	4.0
P9	4.25
P10	4.5

3. Déterminer le points optimal:

- Calculer $\text{centroidDist} = \text{moyenne}(dsum) = 2.175$
- le point m le plus proche est P6.

4. Création des nouveaux centroids:

- C1=p1,p2,p3,p4,p5,p6 et alors c1(2.5 ;2.83)
- C2=p7,p8,p9,p10 et alors c2(6.125 ;5.625)

2.2.1 Avantages de la méthode

- **Distances intra-cluster minimalisées:** Le split sur l'axe de variance maximale garantit que les points dans chaque sous-cluster sont aussi proches que possible entre eux (minimisation de la distance intra-cluster).
- **Distances inter-cluster maximisées:** Les nouveaux centroïdes sont positionnés là où la densité de points est la plus faible, créant une séparation naturelle entre clusters.
- **Équilibre structurel:** Le choix de m via *dsum* assure que les sous-clusters ont des tailles comparables, évitant les déséquilibres.

ainsi, cette méthode améliore la compacité et la séparation des clusters dès l'initialisation, ce qui contribue fortement à la qualité du partitionnement final.

3 Analyse des Résultats Expérimentaux

3.1 Approche expérimentale

Pour évaluer notre méthode G-means améliorée, nous l'avons testée sur 7 Datasets de référence issus de scikit-learn, dont nous connaissons à l'avance le nombre optimal de clusters (k). Cette sélection inclut :

- Jeux de données classiques : Iris ($k=3$), Digits ($k=10$), Wine ($k=3$), Breast Cancer ($k=2$)
- Données synthétiques : Blobs ($k=4$), Moons ($k=2$), Circles ($k=2$)

3.2 Nombre d'itérations pour chaque solution

Pour évaluer l'efficacité de la méthode proposée, on a mesuré le nombre d'itérations nécessaires à la convergence : l'initialisation optimisée (par axe de variance) réduit significativement les itérations par rapport à une initialisation aléatoire, comme le montrent les résultats

DATASET	Iterations	
	initialisation aléatoire	initialisation optimisée
Iris	12	4
Wine	9	6
Blobs	10	5

Table 2: Comparaison du nombre d'itérations nécessaires.

Les résultats montrent une réduction significative du nombre d'itérations nécessaires pour la convergence avec la Solution proposée.

3.3 Comparaison entre k réel et k prédit

1. Précision globale:

- Notre méthode G-means modifiée obtient une similarité moyenne de 93% avec le vrai nombre de clusters (k réel), démontrant une excellente adéquation globale.

2. Résultats par Dataset:

- Prédictions parfaites (100%): (Digits ($k=10 \rightarrow 10$), Breast Cancer ($k=2 \rightarrow 2$), Blobs ($k=4 \rightarrow 4$) et Moons ($k=2 \rightarrow 2$)).
- Erreurs mineures (85%) : Iris ($k=3 \rightarrow 2$), Wine ($k=3 \rightarrow 2$) et Circles ($k=2 \rightarrow 3$) $\rightarrow$ Sous-estimation pour Iris/Wine (fusion de clusters proches) et sur-estimation pour Circles (bruit interprété comme un cluster).




Figure 2: Accuracy comparison.

4 Conclusion

Notre méthode G-means améliorée démontre une forte capacité à prédire le nombre optimal de clusters, avec une précision globale de 93%. Elle surpasse l'initialisation aléatoire en produisant des clusters plus compacts et mieux séparés pour la majorité des jeux de données testés, tout en maintenant une complexité algorithmique raisonnable. Les légères erreurs observées sur les structures complexes (cercles, données haute dimension) ouvrent des pistes d'amélioration futures.

References

- [1] Greg Hamerly and Charles Elkan. Learning the k in k-means. *Advances in neural information processing systems*, 16, 2003. URL: https://proceedings.neurips.cc/paper_files/paper/2003/file/234833147b97bb6aed53a8f4f1c7a7d8-Paper.pdf.
- [2] Deepak Kumar and Lokesh Bhambhu. New fast k-means clustering algorithm using modified centroid selection method. <https://www.ijert.org/research/new-fast-k-means-clustering-algorithm-using-modified-centroid-selection-method-IJERT.pdf>, 2013. International Journal of Engineering Research & Technology (IJERT), Vol. 2, Issue 2.